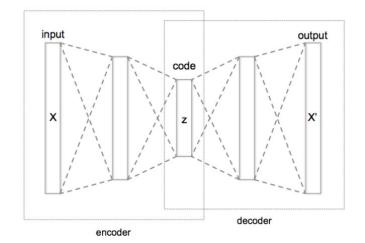
Autoencoders y GANs

Aprendizaje Auto Supervisado / Manifold Learning/ Adversarial Training

Introducción

- Copian la entrada a la salida
- Encoder: h=f(x)
- Decoder: r=g(h)
- Encontrar un autoencoder tal que g(f(x))=x para todo x no es interesante en cuanto a la tarea que realiza, pero resolver esta tarea suele brindar subproductos interesantes si se aplican algunas restricciones adicionales.
 - Ej: Si la dimensionalidad de h es menor que la de la entrada/salida y la reconstrucción es válida, entonces el autoencoder encontró una representación más eficiente que la original.
- Para poder entrenar el modelo hay que definir una medida de error entre la entrada y la salida. Dicha medida debe ser derivable para poder entrenar el modelo.



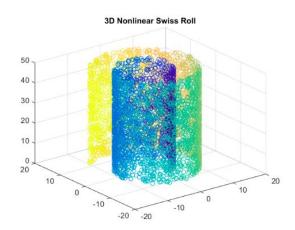
Autoencoders: Aplicaciones

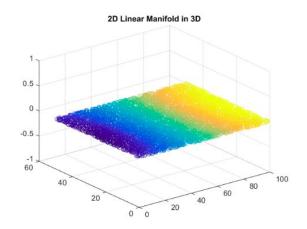
- Reducción de la dimensionalidad (Aprendizaje Semi-Supervisado)
- Detección de anomalías
- Denoising

Undercomplete Autoencoder

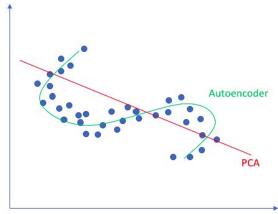
- La idea es que la dimensión de **h** sea menor que la de **x**.
- Aprenden una representación incompleta de los datos de entrada, guiados por una función de costo.
- El objetivo es encontrar una representación que minimice L(x,g(f(x)).
 - Ej:
 - Lineales + MSE: PCA
 - Alineales: Redes Neuronales
- Las varianzas del encoder y del decoder también tienen que ser acotadas ya que en idealmente podrían mapear todo el espacio de entrada en una sola dimensión y de ahí volver a obtener el dato original. Esto no pasa en la práctica pero es un ejercicio interesante para pensar.

Undercomplete Autoencoder (Interpretación)





Linear vs nonlinear dimensionality reduction

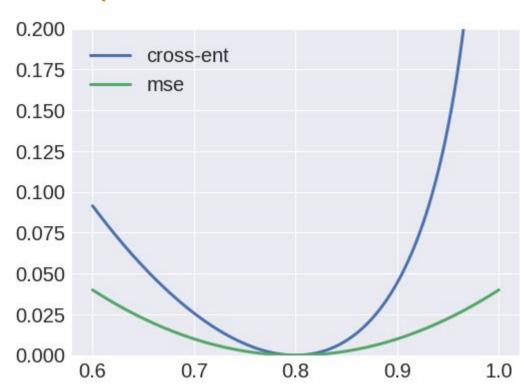


<u>Fuente</u>

Funciones de costo (Discusión)

- MSE
- MAE
- Binary Crossentropy
- Categorical Crossentropy
- Loss para imágenes?

Perceptual Loss



Perceptual Loss

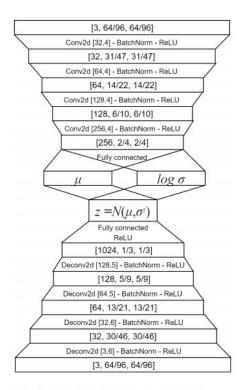


Fig. 4. The convolutional variational autoencoder used in this work.

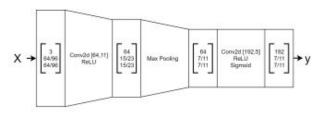


Fig. 3. The parts of a pretrained AlexNet that were used for calculating and backpropagating the perceptual loss.

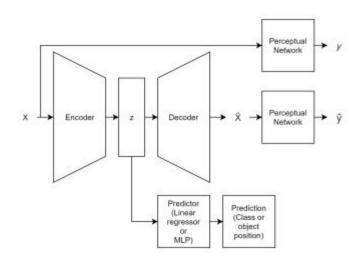


Fig. 5. The system used in this work including both the autoencoding and prediction pathways.

Loss Function

$$E = \sum_{k=1}^{n} f(X_k, a(X)_k)$$

$$\downarrow$$

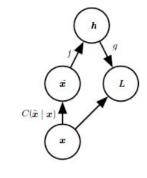
$$E = \sum_{k=1}^{m} f(p(X)_k, p(a(X))_k)$$

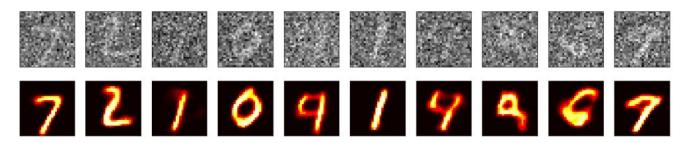
Denoising Autoencoders

- Un DA en vez de minimizar el error de reconstrucción de la salida con respecto a la entrada, minimiza una los dada por:

 $L(\boldsymbol{x}, g(f(\tilde{\boldsymbol{x}})))$

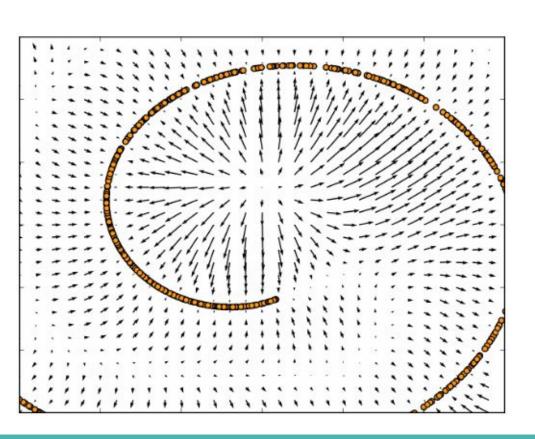
- En este caso la entrada es una versión modificada con ruido del dato original.
- En este caso se pueden utilizar overcompletes autoencoders.

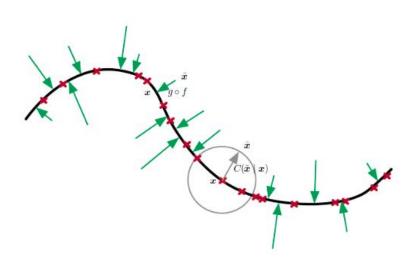




<u>Github</u>

Denoising Autoencoders (Interpretación)



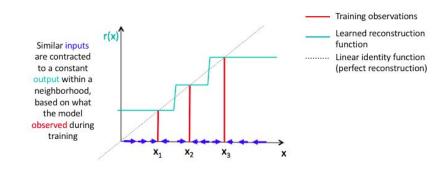


Contractive Autoencoders

- Penalizan altos valores de derivadas de las activaciones de h, con respecto a las entradas.
- Equivale a hacer denoising pero con apartamientos infinitesimales.

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$$

$$\mathbf{J} = egin{bmatrix} rac{\delta a_1^{(h)}(x)}{\delta x_1} & \cdots & rac{\delta a_1^{(h)}(x)}{\delta x_m} \ dots & \ddots & dots \ rac{\delta a_n^{(h)}(x)}{\delta x_1} & \cdots & rac{\delta a_n^{(h)}(x)}{\delta x_m} \end{bmatrix}$$



$$\mathcal{L}\left(x,\hat{x}
ight) + \lambda {\sum_i} \left\|
abla_x a_i^{(h)}\left(x
ight)
ight\|^2$$

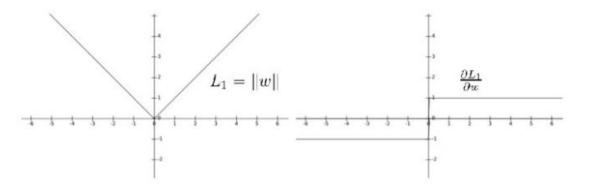
Sparse Autoencoders

- Así como en otro contexto regularizábamos con respecto a los pesos, podemos regularizar con respecto a las activaciones.
- Al agregar un término de regularización L1 con respecto a las activaciones de **h** podemos asegurarnos una representación sparsa (rala) en dimensionalidad reducida.
- En algunos casos las representaciones sparsas representan mejor un problema.
- En el caso de aprendizaje semi-supervisado se ve una mejora en la performance de distintas tareas utilizando representaciones sparsas. Per ejemplo: clasificación de imágenes.

$$Obj = L(x, \hat{x}) + regularization + \lambda \sum_{i} |a_{i}^{(h)}|$$

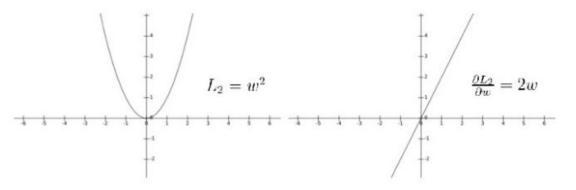
Sparse Autoencoders

Notas de clase de Andrew Ng



L1 regularization and its derivative

model.add(Conv2D(32, (3,3), activity_regularizer=l1(0.001)))

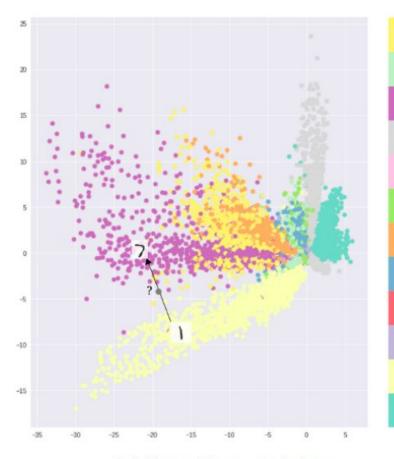


L2 regularization and its derivative

Variational Autoencoders (Link)

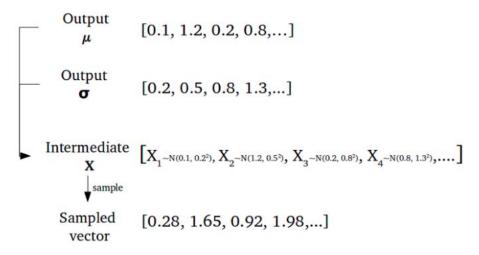
- Los autoencoders vistos hasta ahora resuelven el problema de representación y denoising.
- ¿Podría modelarse la distribución del espacio latente y a partir de esto generar datos nuevos?
 - No hay garantías de la continuidad ni la interpolabilidad del espacio latente.
- El problema son las discontinuidades entre los clusters.
- Durante el entrenamiento no hay datos que se generen desde esas regiones del espacio latente.
 Por lo tanto no se puede estimar qué va a hacer el decoder.

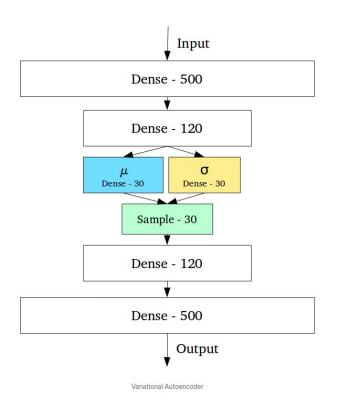
Los VAE tienen por diseño un espacio latente continuo (regularizado) y por lo tanto permiten la interpolación y sampleo para la generación de datos. Link a Keras.js



Optimizing purely for reconstruction loss

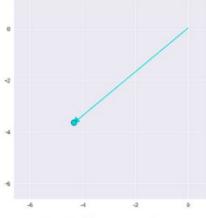
- Los VAE no dan como subproducto un vector en el espacio latente, sino que dan una distribución.
- De esa distribución se muestrea un vector y éste ingresa al autoencoder para generar el dato.



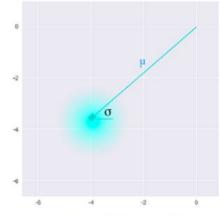


Stochastically generating encoding vectors

 Esto implica que si bien para la misma entrada el encoder nos va a dar a la salida la misma distribución, el decoder va a recibir dos vectores distintos producto del muestreo.

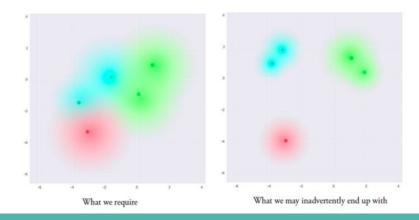


Standard Autoencoder (direct encoding coordinates)

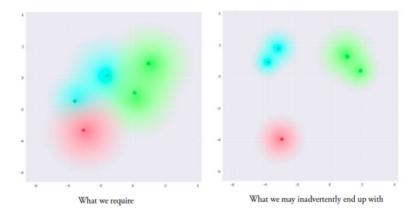


Variational Autoencoder (μ and σ initialize a probability distribution)

- Como el dato debe ser reconstruído correctamente no desde un punto en particular sino que ahora debe ser reconstruído desde un zona del espacio de embeddings, las representaciones van a tener cierto grado de continuidad local.
- También es deseable que haya continuidad entre puntos del espacio de embeddings correspondientes a clases distintas.
- Sin embargo con este tipo de modelo, las muestras tienden a agruparse de la siguiente forma:



- Esto se debe a que no hay restricciones con respecto a los valores que pueden tomar mu y sigma.
- Datos muy distintos pueden ir a parar a mu's muy distintos y eso hace que no tenga control sobre la transición entre clases, o modos de la distribución de entrada.
- Por este motivo, condiciones adicionales deben ser impuestas a los valores de mu y sigma.
- Por forzar a que los puntos estén cerca, podemos pedir que las distribuciones a la salida del encoder se parezcan lo más posible a una distribución conocida. Por ejemplo: Normal (0,1)



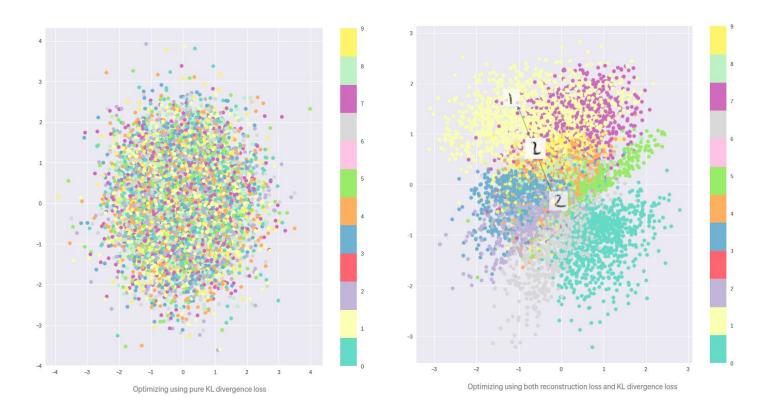
- Una forma de obligar a que los puntos estén aglomerados en el centro del espacio latente es utilizando la divergencia KL entre las distribuciones obtenidas y una distribución de referencia, como la Normal (0,1).
- Para medir distancias entre distribuciones podemos utilizar la DKL entre los valores a la salida del encoder y la Normal (0,1):

$$D_{\mathrm{KL}}(P \parallel Q) = \int_{-\infty}^{\infty} p(x) \log \left(\frac{p(x)}{q(x)}\right) dx \qquad \sum_{i=1}^{n} \sigma_{i}^{2} + \mu_{i}^{2} - \log \left(\sigma_{i}\right) - 1$$

KL Divergence for Continuous Probability Distributions — Wikipedia

Variational Autoencoders (DKL entre gaussianas. Link)

$$\begin{split} &\int \left[\log(p(x)) - \log(q(x))\right] p(x) dx \\ &= \int \left[-\frac{1}{2} \log(2\pi) - \log(\sigma_1) - \frac{1}{2} \left(\frac{x - \mu_1}{\sigma_1}\right)^2 + \frac{1}{2} \log(2\pi) + \log(\sigma_2) + \frac{1}{2} \left(\frac{x - \mu_2}{\sigma_2}\right)^2 \right] \\ &\times \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left[-\frac{1}{2} \left(\frac{x - \mu_1}{\sigma_1}\right)^2 \right] dx \\ &= \int \left\{ \log\left(\frac{\sigma_2}{\sigma_1}\right) + \frac{1}{2} \left[\left(\frac{x - \mu_2}{\sigma_2}\right)^2 - \left(\frac{x - \mu_1}{\sigma_1}\right)^2 \right] \right\} \times \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left[-\frac{1}{2} \left(\frac{x - \mu_1}{\sigma_1}\right)^2 \right] dx \\ &= E_1 \left\{ \log\left(\frac{\sigma_2}{\sigma_1}\right) + \frac{1}{2} \left[\left(\frac{x - \mu_2}{\sigma_2}\right)^2 - \left(\frac{x - \mu_1}{\sigma_1}\right)^2 \right] \right\} \\ &= \log\left(\frac{\sigma_2}{\sigma_1}\right) + \frac{1}{2\sigma_2^2} E_1 \left\{ (X - \mu_2)^2 \right\} - \frac{1}{2\sigma_1^2} E_1 \left\{ (X - \mu_1)^2 \right\} \\ &= \log\left(\frac{\sigma_2}{\sigma_1}\right) + \frac{1}{2\sigma_2^2} E_1 \left\{ (X - \mu_2)^2 \right\} - \frac{1}{2} \end{split}$$
 (Now note that
$$(X - \mu_2)^2 = (X - \mu_1 + \mu_1 - \mu_2)^2 = (X - \mu_1)^2 + 2(X - \mu_1)(\mu_1 - \mu_2) + (\mu_1 - \mu_2)^2) \\ &= \log\left(\frac{\sigma_2}{\sigma_1}\right) + \frac{1}{2\sigma_2^2} \left[E_1 \left\{ (X - \mu_1)^2 \right\} + 2(\mu_1 - \mu_2) E_1 \left\{ X - \mu_1 \right\} + (\mu_1 - \mu_2)^2 \right] - \frac{1}{2} \\ &= \log\left(\frac{\sigma_2}{\sigma_1}\right) + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2} \end{split}$$



Variational Autoencoders: Pytorch - Lightning

```
class VAE(pl.LightningModule):
   def init (self,alpha = 1):
        #Autoencoder only requires 1 dimensional argument since input and output-size is the same
        super(). init ()
        self.encoder = nn.Sequential(nn.Linear(784,196),nn.ReLU(),nn.BatchNormld(196,momentum = 0.7).
                                     nn.Linear(196,49),nn.ReLU(),nn.BatchNorm1d(49,momentum = 0.7),
                                     nn.Linear(49,28),nn.LeakyReLU())
        self.hidden2mu = nn.Linear(28,28)
        self.hidden2log var = nn.Linear(28,28)
        self.alpha = alpha
        self.decoder = nn.Sequential(nn.Linear(28,49),nn.ReLU(),
                                     nn.Linear(49,196),nn.ReLU(),
                                     nn.Linear(196,784),nn.Tanh())
        self.data transform = transforms.Compose([
                                                    transforms.ToTensor(),
                                                    transforms.Normalize(mean=(0.5,),std=(0.5,))])
   def encode(self.x):
        hidden = self.encoder(x)
       mu = self.hidden2mu(hidden)
       log var = self.hidden2log var(hidden)
        return mu, log var
   def reparametrize(self,mu,log var):
        #Reparametrization Trick to allow gradients to backpropagate from the
        #stochastic part of the model
        sigma = torch.exp(0.5*log var)
       z = torch.randn(size = (mu.size(0), mu.size(1)))
        z= z.type as(mu)
       return mu + sigma*z
   def decode(self,x):
        x = self.decoder(x)
        return x
```

Variational Autoencoders: Implementación

```
def configure optimizers(self):
    return Adam(self.parameters(), lr = 1e-3)
def forward(self,x):
    batch size = x.size(0)
    x = x.view(batch size, -1)
    mu.log var = self.encode(x)
    hidden = self.reparametrize(mu,log var)
    return self.decoder(hidden)
# Functions for dataloading
def train dataloader(self):
    mnist train = MNIST('data/', download = True, train = True, transform=self.data transform)
    return DataLoader(mnist train, batch size=64, num workers=12)
def val dataloader(self):
    mnist val = MNIST('data/',download = True,train = False,transform=self.data transform)
    return DataLoader(mnist val,batch size=64,num workers=12)
def scale image(self,img):
    out = (img + 1) / 2
    return out
```

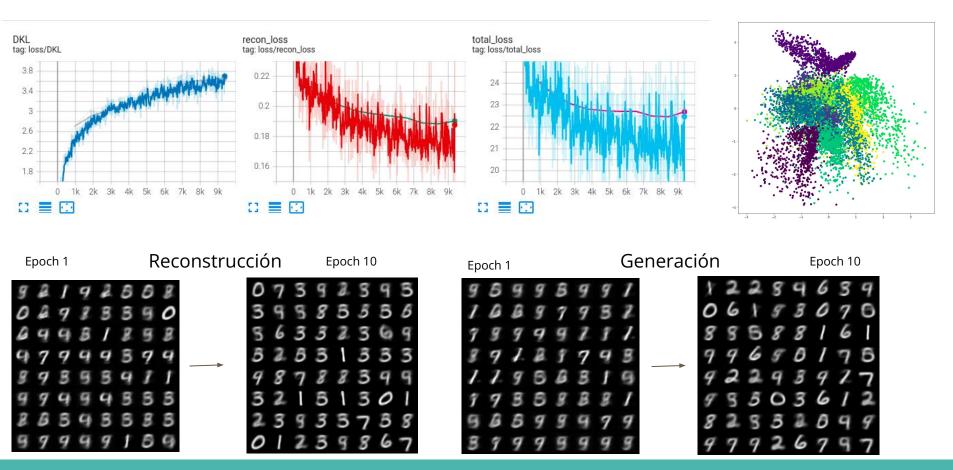
Variational Autoencoders: Implementación

```
def training step(self,batch,batch idx):
    x, = batch
    batch size = x.size(0)
    x = x.view(batch size, -1)
    mu, log var = self.encode(x)
    kl_{loss} = (-0.5*(1+log_{var} - mu**2 - torch.exp(log_{var})).sum(dim = 1)).mean(dim = 0)
    hidden = self.reparametrize(mu,log var)
    x out = self.decode(hidden)
    recon loss criterion = nn.MSELoss()
    #print(kl loss.item(), recon loss.item())
    recon loss criterion = nn.MSELoss()
    recon loss = recon loss criterion(x,x out)
    loss = recon loss*self.alpha + kl loss
    self.logger.experiment.add scalars('loss/DKL',{'train':kl loss},global step=self.global step)
    self.logger.experiment.add scalars('loss/recon loss',{'train':recon loss},global step=self.global step)
    self.logger.experiment.add scalars('loss/total loss',{'train':loss},global step=self.global step)
    return loss
```

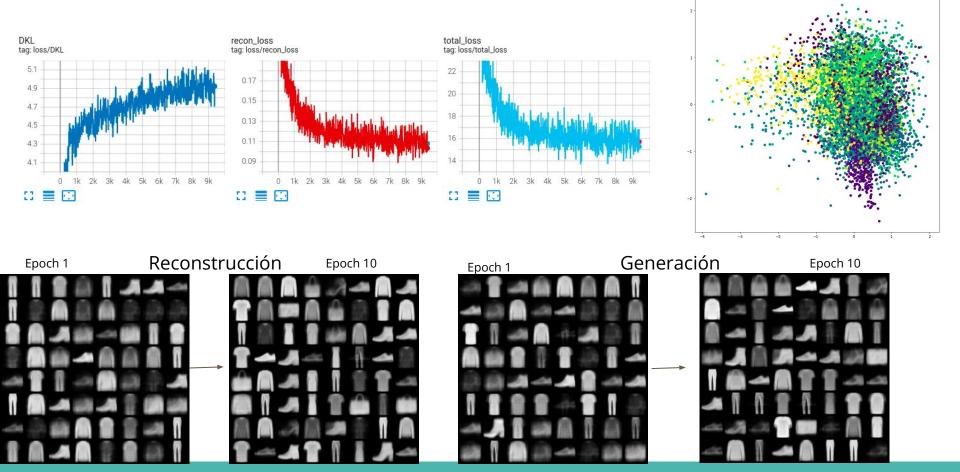
Variational Autoencoders: Implementación

```
def validation step(self,batch,batch idx):
    x, = batch
    batch size = x.size(0)
    x = x.view(batch size.-1)
    mu, log var = self.encode(x)
    kl loss = (-0.5*(1+log var - mu**2 - torch.exp(log var)).sum(dim = 1)).mean(dim = 0)
    hidden = self.reparametrize(mu,log var)
    x out = self.decode(hidden)
    recon loss criterion = nn.MSELoss()
    recon loss = recon loss criterion(x,x out)
    #print(kl loss.item(), recon loss.item())
    loss = recon loss*self.alpha + kl loss
    return x out, {"loss": loss, "rec": recon loss, "kl loss, "batch": batch}
def validation epoch end(self,outputs):
    avg loss = torch.stack([x[1]['loss'] for x in outputs]).mean()
    avg rec = torch.stack([x[1]['rec'] for x in outputs]).mean()
    avg dist = torch.stack([x[1]['kl loss'] for x in outputs]).mean()
    self.logger.experiment.add scalars(
        "loss/total loss",
        {"val": avg loss},
        global step=self.global step
    self.logger.experiment.add scalars(
        "loss/recon loss",
        {"val": avg rec},
        global_step=self.global step
    self.logger.experiment.add scalars(
        "loss/DKL",
        {"val": avg dist},
        global step=self.global step
    if not os.path.exists('vae images'):
        os.makedirs('vae images')
    choice = random.choice(outputs)
    output sample = choice[0]
    output sample = output sample.reshape(-1, 1, 28, 28)
    output sample = self.scale image(output sample)
    save image(output sample, f"vae images/epoch {self.current epoch+1}.png")
```

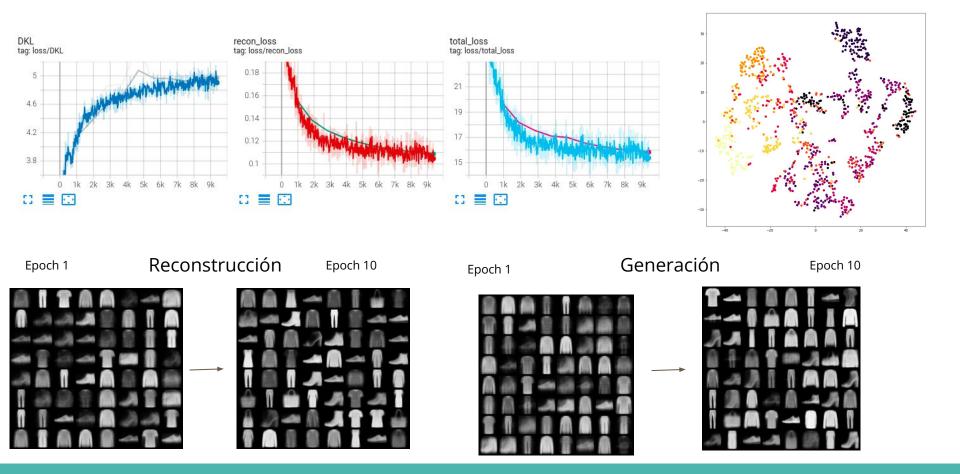
Variational Autoencoder: Entrenamiento



Variational Autoencoder: Entrenamiento (hidden=2)

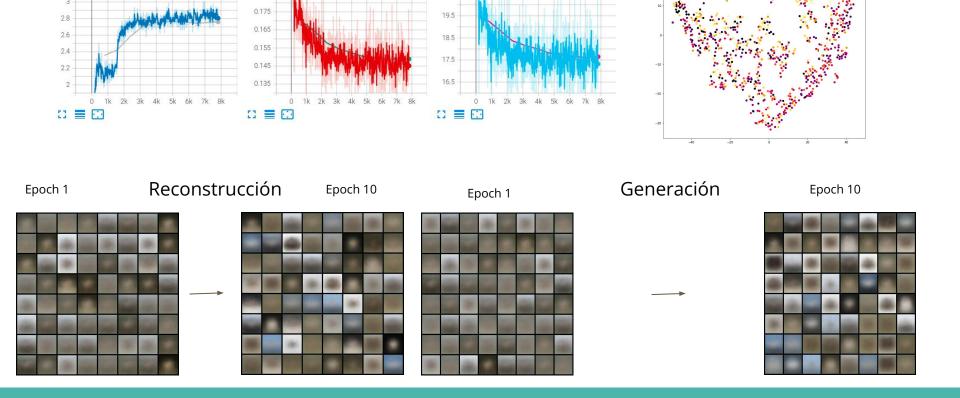


Variational Autoencoder: Entrenamiento (hidden=28)



VAE: Entrenamiento (hidden=28). CIFAR10

recon_loss



total_loss tag: loss/total_loss

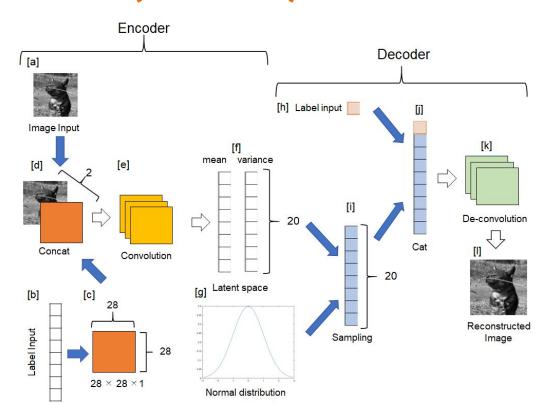
Soluciones a CIFAR10

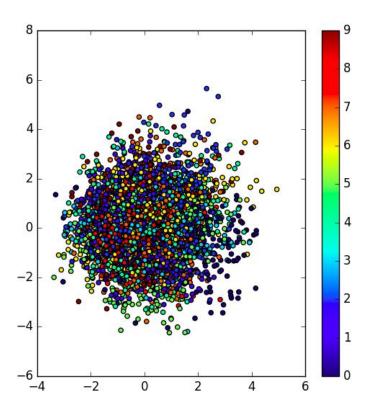
- CVAEs
- DC-VAEs
- DC-CVAEs
- GANs
- DC-GANs
- DC-CGANs

VAE-DCGANs (Blog de VAE)

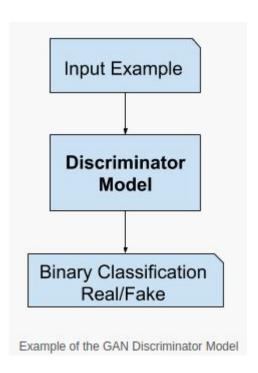


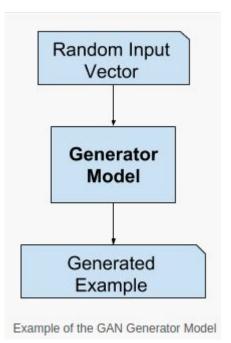
CVAEs (Link, Link)

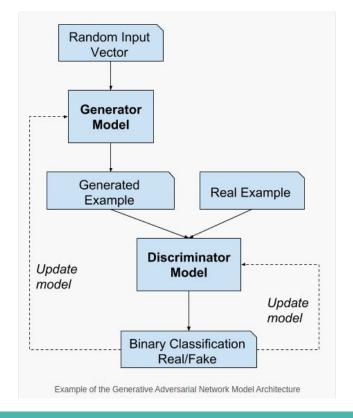




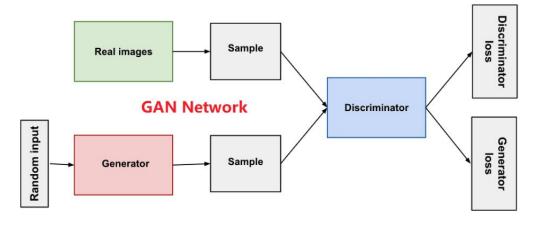
GANs (Generative Adversarial Networks) (Link)







SimpleGAN: Implementación



```
class Generator(nn.Module):
   def init (self, latent dim, dim):
        super(). init ()
        self.dim = 2
        def block(in feat, out feat, normalize=True):
            layers = [nn.Linear(in feat, out feat)]
           if normalize:
                layers.append(nn.BatchNormld(out feat))
            layers.append(nn.ReLU(inplace=True))
            return layers
        self.model = nn.Sequential(
            *block(latent dim, 128, normalize=False),
            *block(128, 256, normalize=True),
            *block(256, 512, normalize=True),
            *block(512, 1024, normalize=True),
           nn.Linear(1024, self.dim),
   def forward(self, z):
        data = self.model(z)
        return data
```

Simple GAN: Implementación

```
class GAN(pl.LightningModule):
   def init (
       self.
       dim,
       latent dim: int = 100,
       lr: float = 0.0002.
      b1: float = 0.5,
       b2: float = 0.9.
       **kwargs
   ):
       super(), init ()
       self.save hyperparameters()
       # networks
       self.generator = Generator(latent dim=self.hparams.latent dim, dim=dim)
       self.discriminator = Discriminator(dim=dim)
       self.validation z = torch.randn(8, self.hparams.latent dim)
   def forward(self, z):
       return self.generator(z)
   def adversarial loss(self, y hat, y):
       return F.binary cross entropy(y hat, y)
```

```
def configure_optimizers(self):
    lr = self.hparams.lr
    bl = self.hparams.bl
    b2 = self.hparams.b2

    opt_g = torch.optim.Adam(self.generator.parameters(), lr=lr, betas=(self.hparams.bl, self.hparams.b2))
    opt_d = torch.optim.Adam(self.discriminator.parameters(), lr=lr, betas=(self.hparams.bl, self.hparams.b2))
    return [opt_g, opt_d], []

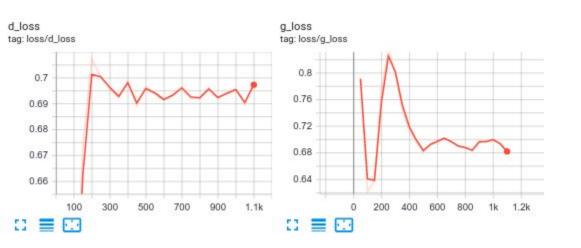
def on_epoch_end(self):
    z = self.validation_z.type_as(self.generator.model[0].weight)
```

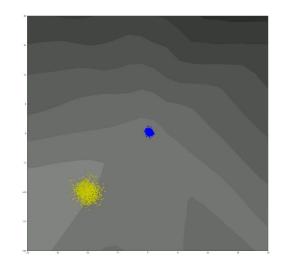
SimpleGAN: Implementación

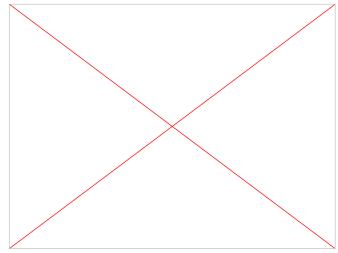
```
def training step(self, batch, batch idx, optimizer idx):
    data, = batch
   # sample noise
   z = torch.randn(data.shape[θ], self.hparams.latent dim)
   z = z.type as(data)
   # train generator
   if optimizer idx == 0:
       for param in self.discriminator.parameters():
            param, requires grad = False
        for param in self.generator.parameters():
           param.requires grad = True
        # generate images
        self.generated data = self(z)
       # ground truth result (ie: all fake)
        # put on GPU because we created this tensor inside training loop
        valid = torch.ones(data.size(0), 1)
        valid = valid.type as(data)
        # adversarial loss is binary cross-entropy
        q loss = self.adversarial loss(self.discriminator(self.generated data), valid)
        tqdm dict = {'q loss': q loss}
        output = OrderedDict({
            'loss': g loss,
            'progress bar': tqdm dict,
            'log': tqdm dict
        return output
    # train discriminator
    if optimizer idx == 1:
       # Measure discriminator's ability to classify real from generated samples
        for param in self.discriminator.parameters():
            param.requires grad = True
        for param in self.generator.parameters():
           param.requires grad = False
        # how well can it label as real?
        valid = torch.ones(data.size(0), 1)
        valid = valid.type as(data)
        real loss = self.adversarial loss(self.discriminator(data), valid)
        # how well can it label as fake?
        fake = torch.zeros(data.size(0), 1)
        fake = fake.type as(data)
        fake loss = self.adversarial loss(
           self.discriminator(self.generated data.detach()), fake)
        # discriminator loss is the average of these
        d loss = (real loss + fake loss) / 2
        tqdm dict = {'d loss': d loss}
        output = OrderedDict({
            'loss': d loss,
            'progress bar': tgdm dict,
            'log': tqdm dict
        return output
```

Dataset 1: Gaussiana 2D mu=(-10,-10), sigma=1

Caso: Discriminador y Generador de Alta Varianza

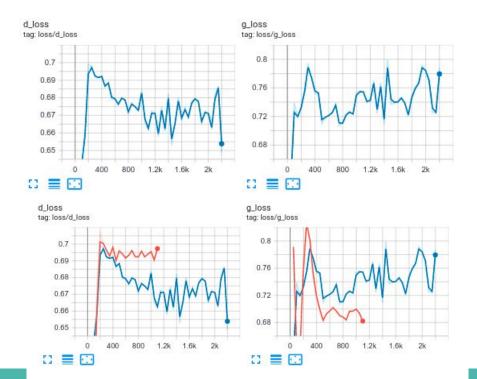


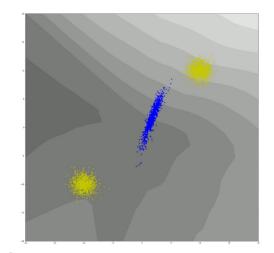


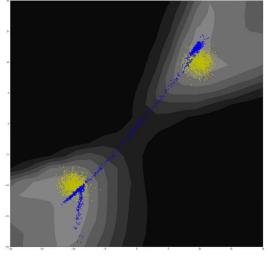


Dataset 2: GMM 2D mu=[(-10,-10), (10,10)], sigma=1

Caso: Discriminador y Generador de Alta Varianza

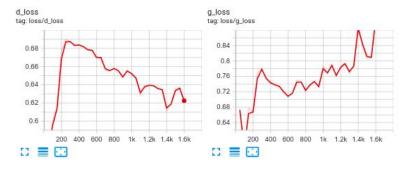


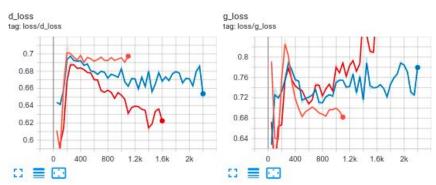


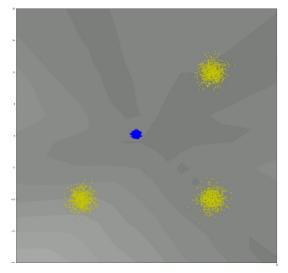


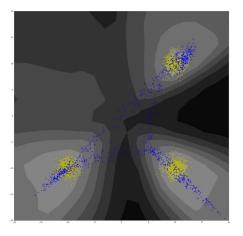
Dataset 3: GMM 2D mu=[(-10,-10), (10,10), (10,-10)], sigma=1

Caso: Discriminador y Generador de Alta Varianza



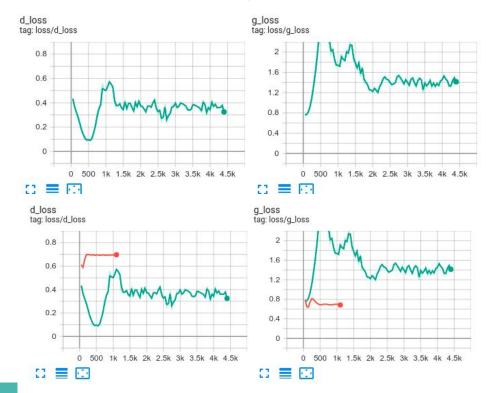


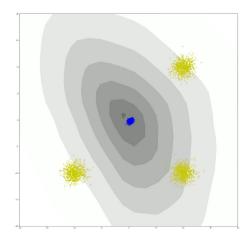


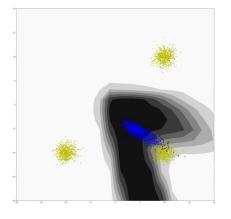


Dataset 3

Caso: Discriminador AV y Generador BV

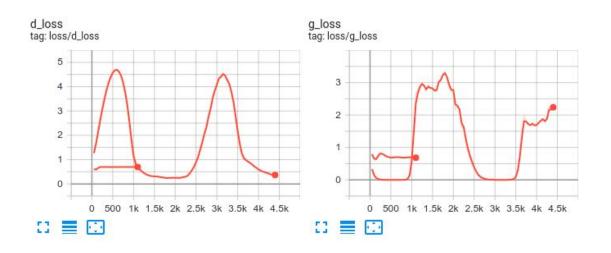


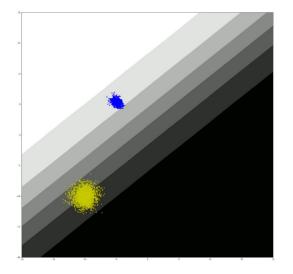


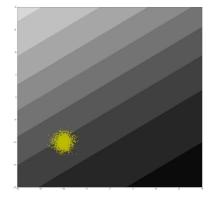


Dataset 1

Caso: Discriminador BV y Generador AV

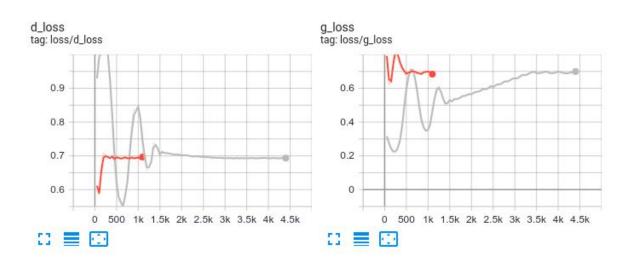


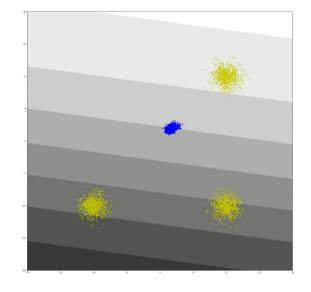


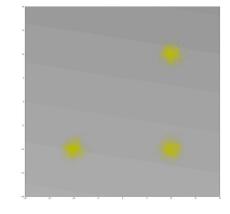


Dataset 3

Caso: Discriminador BV y Generador AV

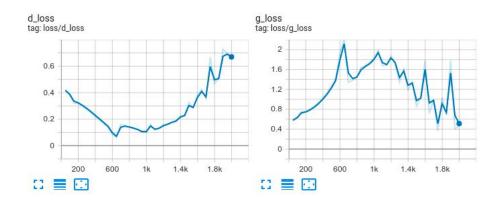


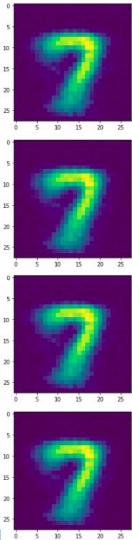




Dataset MNIST-7

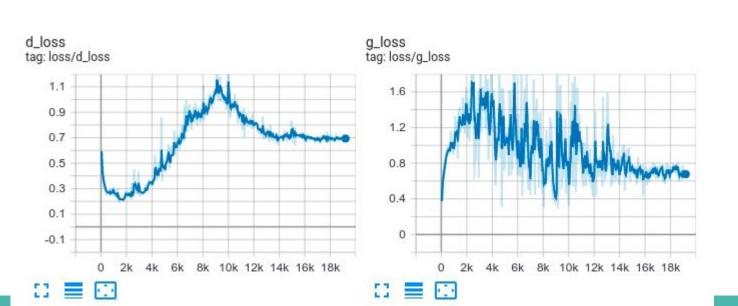
Caso: Discriminador AV y Generador AV

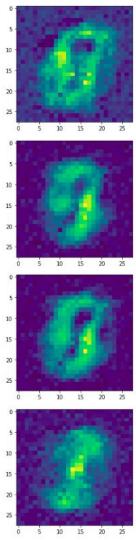




Dataset MNIST

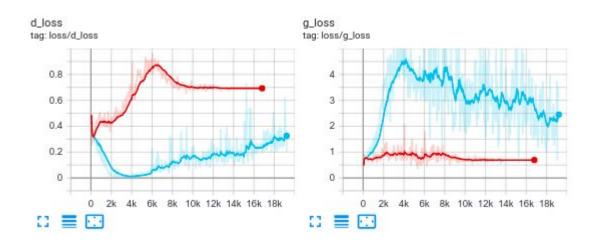
Caso: Discriminador ?? y Generador ?? (Según lo visto anteriormente, le falta varianza al discriminador)

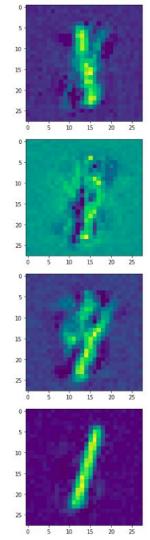




Dataset MNIST

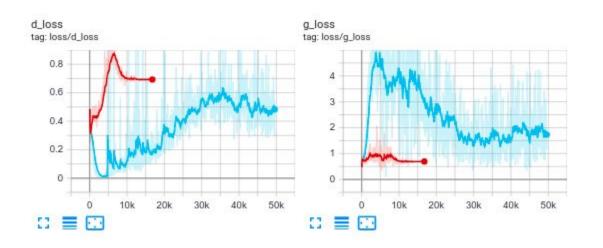
Caso: Discriminador ?? y Generador ?? (Según lo visto anteriormente, le falta varianza al discriminador)

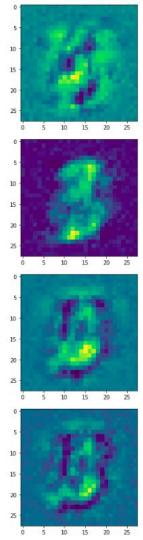




Dataset MNIST

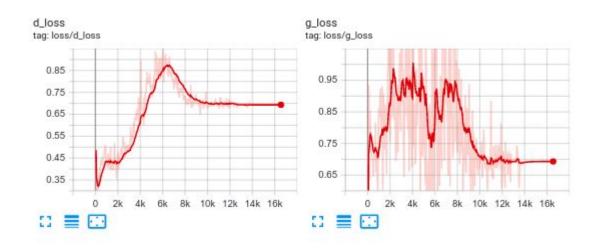
Caso: Discriminador ?? y Generador ?? (El discriminador está ok, le falta varianza al generador)

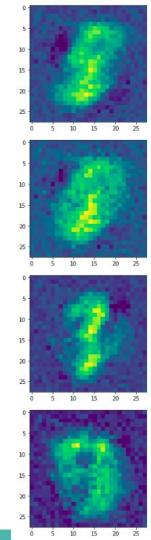




Dataset MNIST

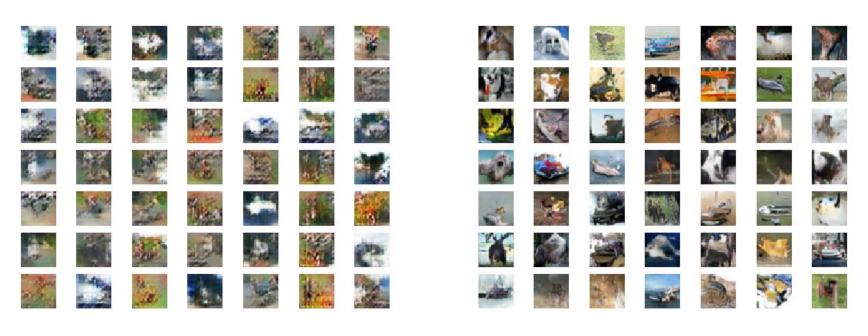
Caso: Discriminador == y Generador +V





DCGAN: CIFAR-10

How to Develop a GAN to Generate CIFAR10 Small Color Photographs



10 epochs 200 epochs